Parcial: Localización y Movimiento

I-402 – Principios de la Robótica Autónoma
Universidad de San Andrés – Escuela de Ingeniería
Joaquín Di Cola – Octubre de 2026

1. Introducción

El objetivo de este trabajo fue implementar y evaluar un sistema de localización para un robot móvil, combinando información de odometría con observaciones del entorno. Se desarrollaron dos algoritmos probabilísticos: un filtro de partículas, que utiliza mediciones LiDAR y un mapa de ocupación, y un filtro de Kalman extendido (EKF), que corrige la estimación mediante landmarks conocidos. Ambos métodos se integraron con los algoritmos de planificación A* y seguimiento Pure Pursuit desarrollados previamente.

Finalmente, se evaluó el filtro de partículas utilizando una grabación de sensores obtenida con un robot real. A continuación se presentan las decisiones principales de implementación, los experimentos realizados y los resultados obtenidos.

2. Filtro de partículas

2.1. Implementación

El filtro de partículas aproxima la distribución de probabilidad de la pose del robot mediante un conjunto de N hipótesis ponderadas. Cada partícula representa un estado $\mathbf{x}^{[i]} = (x^{[i]}, y^{[i]}, \theta^{[i]})$ y posee un peso que indica su compatibilidad relativa con las observaciones.

Para evaluar las mediciones LiDAR se construyó un campo de verosimilitud a partir del mapa de ocupación. Mediante una transformada de distancia euclidiana se calculó la distancia de cada celda al obstáculo más cercano. La verosimilitud se definió como:

$$L(d) = \exp\left(-\frac{d^2}{2\sigma^2}\right), \tag{1}$$

donde d representa la distancia al obstáculo, expresada en celdas de la grilla, y σ controla la dispersión del campo.

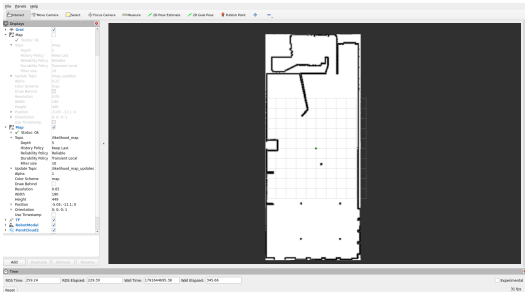


Figura 1: Campo de verosimilitud generado a partir del mapa de ocupación.

Las partículas se inicializan mediante `/initialpose`, utilizando una distribución gaussiana alrededor de la posición seleccionada. La configuración de referencia empleó desviaciones estándar de 0.20 m en posición y 10° en orientación, con 1000 partículas y pesos inicialmente uniformes.

En cada actualización de odometría, las partículas se desplazan según el movimiento relativo del robot, incorporando ruido gaussiano para representar la incertidumbre. Posteriormente, el LiDAR permite corregir la distribución: se calculan los extremos de 12 rayos seleccionados y se consulta su compatibilidad con el campo de verosimilitud. Para este cálculo se tuvo en cuenta el desplazamiento longitudinal de 0.043 m y la rotación de 180° del sensor.

Para mejorar la estabilidad numérica se acumularon los pesos en escala logarítmica y se suavizó la probabilidad de cada observación mediante $L_s(d) = 0.15 + 0.85L(d)$. El remuestreo sistemático se ejecuta cuando el número efectivo de partículas cumple:

$$N_{\text{eff}} = \frac{1}{\sum_{i=1}^{N}(w^{[i]})^2} < \frac{N}{2}. \tag{2}$$

Luego del remuestreo se incorpora una pequeña perturbación para evitar que todas las partículas se concentren en hipótesis idénticas. La pose estimada se calcula mediante la media ponderada de las posiciones y la media circular de las orientaciones, y se publica en `/particle_odom`.

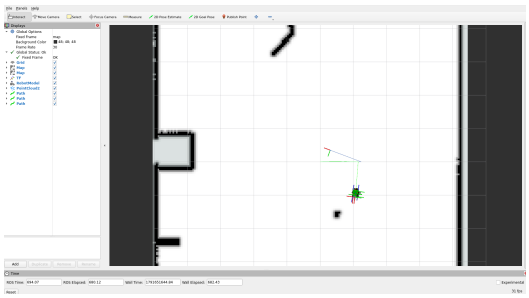


Figura 2: Evolución y concentración de las partículas durante el movimiento.

2.2. Planificación y navegación

La pose corregida se utilizó como entrada del planificador A* y del controlador Pure Pursuit. Para mejorar la seguridad, se incorporó una inflación de obstáculos de 0.20 m: las celdas demasiado próximas a una ocupación dejan de considerarse transitables. También se modificó el controlador para que el robot gire sobre su eje cuando el error angular hacia el objetivo de seguimiento supera aproximadamente 30°. Esta corrección evita que avance en una dirección incorrecta cuando el objetivo se encuentra detrás de su orientación actual.

Con una configuración de 1000 partículas se comprobó que el robot podía seguir el camino planificado, alcanzar el objetivo y detenerse. También se realizaron pruebas con 500 y 2000 partículas, observando seguimiento del recorrido, aunque sin verificar con el mismo nivel de certeza la detención final en ambos casos.

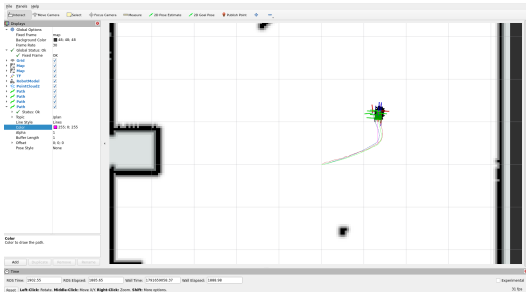


Figura 3: Navegación autónoma utilizando la pose corregida por el filtro de partículas.

2.3. Análisis de parámetros

Se estudió la influencia de σ, la dispersión inicial y la cantidad de partículas. Con $\sigma = 0.5$ el campo de verosimilitud resulta más selectivo, por lo que errores pequeños en las mediciones pueden reducir considerablemente los pesos. Con $\sigma = 3$ la probabilidad se distribuye sobre una región mayor, haciendo al filtro más tolerante, aunque menos discriminativo. En las pruebas estacionarias ambos valores permitieron concentrar las partículas, sin observarse una diferencia concluyente en la convergencia.

También se probó una inicialización más dispersa, con desviaciones de 0.50 m y 25°. Las partículas cubrieron inicialmente una región más amplia y luego se concentraron mediante las observaciones. Una dispersión muy pequeña puede excluir la pose verdadera, mientras que una demasiado grande exige más partículas para representar adecuadamente las posibles ubicaciones.

En cuanto al número de partículas, se realizaron ensayos con 500, 1000 y 2000. Una población mayor permite representar más hipótesis, pero aumenta el costo de procesamiento. No se identificó experimentalmente un número mínimo a partir del cual el filtro dejara de converger; además, los objetivos de navegación fueron ligeramente diferentes, por lo que estas pruebas no constituyen una comparación controlada de precisión.

Finalmente, el campo de verosimilitud podría utilizarse para penalizar recorridos cercanos a obstáculos. En este trabajo se adoptó una alternativa basada directamente en la distancia: la inflación de 0.20 m utilizada por A*.

3. Filtro de Kalman extendido

3.1. Implementación

El EKF estima la pose del robot mediante una distribución gaussiana definida por el vector de estado $\boldsymbol{\mu} = (x, y, \theta)^T$ y la matriz de covarianza Σ. A diferencia del filtro de partículas, mantiene una estimación central y una aproximación local de su incertidumbre.

La inicialización se realizó mediante `/initialpose`, utilizando desviaciones estándar de 0.50 m para posición y 10° para orientación. La predicción utiliza los incrementos de odometría y propaga la incertidumbre mediante:

$$\overline{\boldsymbol{\mu}}_t = f(\boldsymbol{\mu}_{t-1}, \mathbf{u}_t), \qquad \overline{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + Q, \tag{3}$$

donde G_t es el jacobiano del modelo de movimiento y Q representa su incertidumbre. Inicialmente se utilizó $Q = \mathrm{diag}(0.02, 0.02, 0.02)$.

La corrección se realiza mediante referencias del mapa. El nodo recibe las posiciones conocidas desde `/landmarks` y las observaciones relativas desde `/observed_landmarks`. Se descartan las entradas no observadas y se asocian las mediciones válidas con los landmarks posibles.

El modelo de medición considera el rango y la dirección de cada referencia:

$$h(\boldsymbol{\mu}, l) = \begin{bmatrix} \sqrt{(l_x - x)^2 + (l_y - y)^2} \\ \mathrm{atan2}(l_y - y, l_x - x) - \theta \end{bmatrix}. \tag{4}$$

Utilizando el jacobiano H_t de esta función, se calcula la ganancia de Kalman y se corrige la pose:

$$K_t = \overline{\Sigma}_t H_t^T (H_t \overline{\Sigma}_t H_t^T + R)^{-1}, \qquad \boldsymbol{\mu}_t = \overline{\boldsymbol{\mu}}_t + K_t \mathbf{y}_t. \tag{5}$$

Se consideraron desviaciones estándar de medición de 0.06 m para rango y 0.07 rad para dirección. La innovación angular se normaliza para evitar discontinuidades. La estimación corregida se publica en `/pose_with_covariance`.

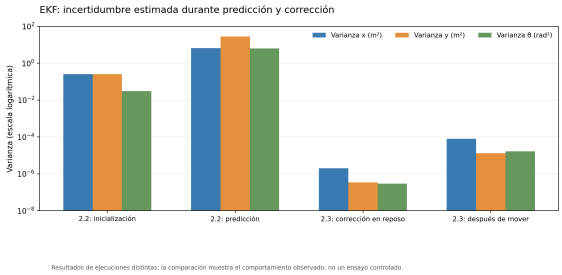


Figura 4: Comparación de la incertidumbre del EKF durante las pruebas.

3.2. Navegación y resultados

Se adaptaron los nodos de A* y Pure Pursuit para que puedan utilizar alternativamente `/particle_odom` o `/pose_with_covariance`, seleccionando la fuente mediante el parámetro `localization_source`.

Durante la prueba con EKF, el planificador publicó un recorrido de 93 puntos y el robot logró llegar al objetivo. Se conservaron las mejoras de seguridad implementadas previamente: inflación de obstáculos y giro previo cuando existe un error de orientación significativo.

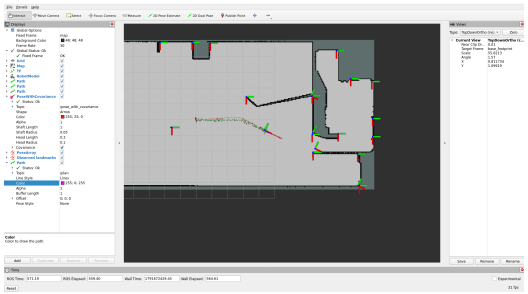


Figura 5: Navegación autónoma con A*, Pure Pursuit y la pose estimada por el EKF.

3.3. Sensibilidad a los parámetros

Se compararon tres incertidumbres iniciales: 0.10 m y 3°, 0.50 m y 10°, y 1.00 m y 25°. Con suficientes landmarks, las tres configuraciones redujeron rápidamente su covarianza. También se introdujo un error inicial deliberado de 0.30 m: los ensayos con las configuraciones pequeña y grande terminaron con errores de posición aproximados de 4.7 mm y 16.8 mm, respectivamente. Por lo tanto, en este escenario ambas pudieron recuperar una estimación cercana a la posición real, aunque los resultados no permiten determinar cuál es superior en general.

Para evaluar la matriz de ruido del movimiento se utilizaron tres valores de $Q = qI_3$. Los resultados se presentan en la Tabla 1.

Cuadro 1: Resultados experimentales para diferentes valores de Q.

q	Recorrido aprox.	Varianza X	Error XY
0.002	0.62 m	7.72×10^{-5}	3.74 mm
0.020	0.61 m	2.54×10^{-5}	6.79 mm
0.200	0.70 m	5.12×10^{-5}	2.72 mm

Los tres valores produjeron errores inferiores a 1 cm en los recorridos evaluados, pero no se observó una relación monótona entre Q y el error final. Una matriz Q pequeña expresa mayor confianza en el movimiento, mientras que una grande permite que las observaciones tengan mayor influencia relativa. Dado que los recorridos no fueron idénticos, los resultados no permiten seleccionar un valor óptimo.

También se evaluó el campo de visión del sensor de landmarks. Con 60° inicialmente no se observaron

referencias y, después de girar, se detectaron seis, de las cuales se utilizaron entre una y dos. Con 360° se observaron 21 landmarks y se utilizaron normalmente entre 18 y 21. Un campo de visión amplio facilita las correcciones, aunque su efectividad continúa dependiendo de que las asociaciones sean correctas.

3.4. Comportamiento con pocas referencias

Se evaluó especialmente una región cercana a la barra y la pared exterior del café, donde disminuyó la cantidad de landmarks utilizables. Durante el recorrido, las referencias observadas pasaron de aproximadamente 21 a solo tres y, finalmente, el filtro registró repetidamente que ninguna observación podía asociarse.

En esa condición la covarianza creció considerablemente. La posición estimada fue aproximadamente $(-2.4225, 3.8800)$ m, mientras que la posición real fue $(-2.3990, 4.4375)$ m. El error euclidiano alcanzó aproximadamente 0.558 m, muy superior a los errores de pocos milímetros observados en zonas con abundantes referencias.

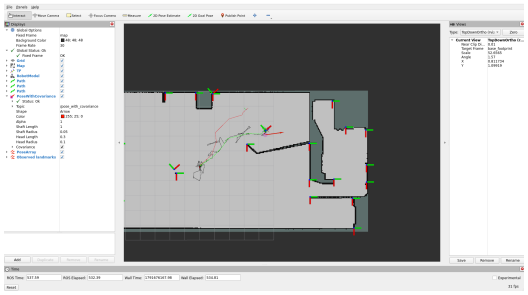


Figura 6: Desviación del EKF en una región sin asociaciones válidas de landmarks.

Este resultado evidencia que detectar landmarks no es suficiente: es necesario poder asociarlos correctamente. Cuando el EKF no dispone de observaciones utilizables, la incertidumbre del movimiento se acumula y la estimación puede separarse de la pose real.

4. Evaluación con datos del robot real

Como última etapa se utilizó el rosbag provisto, con una duración de 163.86 s y un total de 23 986 mensajes. La grabación contiene 1633 mensajes de odometría y 1188 mediciones LiDAR. Se ejecutó el filtro de partículas con 1000 hipótesis, utilizando los tópicos `/odom` y `/scan`. Para recibir correctamente las mediciones del LiDAR fue necesario verificar la compatibilidad del perfil QoS *Best Effort*.

Se realizaron dos reproducciones. En la primera se inicializó el filtro cuando ya habían transcurrido aproximadamente 17 segundos. Para mejorar el procedimiento, en la segunda prueba se inicializó la distribución cerca del tercer segundo y se registraron todas las estimaciones publicadas en `/particle_odom`.

La segunda ejecución produjo 1171 posiciones estimadas. La posición inicial registrada fue $(0.01296, 0.00202)$ m y la final $(0.75889, 0.19356)$ m. La distancia de cierre se calculó como:

$$d_c = \sqrt{(x_f - x_0)^2 + (y_f - y_0)^2} = \boxed{0.7701 \text{ m}}. \tag{6}$$

La grabación se procesó completamente y el filtro actualizó su estimación durante el recorrido. Sin embargo, se observaron desviaciones importantes entre las trayectorias, incluidos segmentos incompatibles con los límites del mapa. Además, la estimación final quedó a aproximadamente 77 cm de la inicial, cuando se esperaba que ambas fueran cercanas.

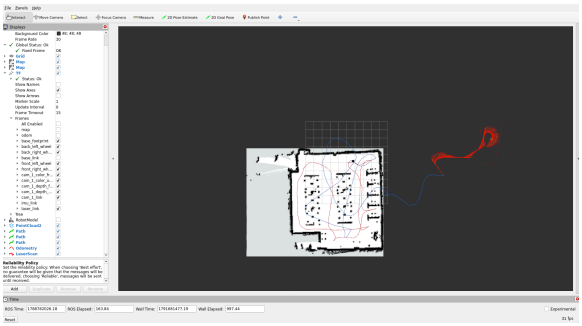


Figura 7: Segunda reproducción del rosbag: trayectorias de odometría y del filtro de partículas.

Este valor constituye una medida del cierre de la trayectoria estimada y no un error absoluto de localización, dado que no se dispone de *ground truth*. Entre las posibles causas se encuentran la alineación inicial entre odometría y mapa, las diferencias entre el LiDAR real y el modelo empleado en simulación, y una calibración de ruido que no fue ajustada específicamente para estos datos. Estas hipótesis requerirían ensayos adicionales para confirmarse.

5. Conclusiones

Se implementaron dos métodos probabilísticos de localización y se integraron exitosamente con A* y Pure Pursuit en simulación. El filtro de partículas permitió estimar la pose mediante odometría y LiDAR, mientras que el EKF utilizó landmarks conocidos para reducir la incertidumbre. Las pruebas mostraron la importancia de los parámetros de ruido, la dispersión inicial y la disponibilidad de observaciones válidas.

La evaluación con datos reales confirmó que el filtro de partículas podía procesar una grabación completa, aunque su estimación presentó desviaciones y un cierre imperfecto de 0.7701 m. Esto demuestra que el funcionamiento del algoritmo en simulación no garantiza por sí solo una localización precisa en un entorno real, donde la calibración de sensores y la incertidumbre del modelo adquieren mayor importancia.